1 Grandes Desvios: Um Estudo dos Desenvolvimentos Recentes e Relações com EDPs

No estudo de sistemas que contém muitas partículas em geral é empregado métodos advindos da teoria de probabilidade para simplificar o trabalho, considerando, em algum limite (e.g., o limite termodinâmico) grandezas macroscópicas.
Em termos da teoria de probabilidade esse limite corresponde ao Teorema dos Grandes Números. Há, porém, outros dois teoremas associados à esse limite e que correspondem a outros dois aspectos deste: o desvio moderado da média e o desvio grande da média, que representa os eventos raros. O primeiro tipo de limite é tratado pelos teoremas do tipo « do limite central » e o segundo pelos teoremas de « grandes desvios. »
Para ilustrar a diferença consideramos variáveis aleatórias na reta real idênticas igualmente distribuídas (va iid)—este foi o cenário da primeira formulação de grandes desvios, feita através do teorema de Cramèr, o qual enunciaremos abaixo, bem como a generalização para va em $\mathbb{R}^d$, que inspira a definição em espaços mais gerais. Ou seja, tomamos uma coleção $\{X_n\}$ de va iid na reta real com uma lei comum μ e esperança $EX_n = m$. Sejam

$$\overline{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i$$

e $A \in \mathcal{B}(\mathbb{R})$ um boreliano cujo fecho não contém a média m: i.e., $m \notin A$. No primeiro caso, viz., no caso tratado pelo Teorema dos Grandes Números estamos interessados em eventos do tipo[1] $\{\overline{X}_n \notin A\}$. No caso tratado pelo Teorema Central do Limite tomamos um A da forma

$$A = [m + \frac{\delta}{\sqrt{n}}, \infty),$$

onde $\delta > 0$ e estudamos os eventos $\{\overline{X}_n \in A\}$. Ou seja, neste caso A tende à $[m, \infty)$, que contém m. Por outro lado, o caso tratado pelo Teorema dos Grandes Desvios é aquele em que A é da forma

$$[m + \delta, \infty),$$

$\delta > 0$—ou seja, um caso onde os eventos são, de fato, raros.

[1] Um resultado do Teorema dos Grandes Números é, precisamente, que

$$\lim_{n\to\infty} P(\overline{X}_n \in A) = 0.$$

1.1 Teorema de Cramèr

Abaixo enunciaremos o Teorema de Cramèr-Chernoff e uma generalização para variáveis aleatórias em $\mathbb{R}^d$:

Teorema 1.1 (Cramèr-Chernoff)**.** *Sejam $\{X_n\}$ va's iid com lei comum μ,*

$$\overline{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i$$

e

$$\hat{\mu}(t) := Ee^{tX_1}, \;\; t \in \mathbb{R}.$$

Definimos

$$\lambda_\mu(x) := \sup_{t\in\mathbb{R}}\{tx - \log\hat{\mu}(t)\}.$$

Então:
(a) *Se X_1 for integrável e $m = EX_1$ valem:*

1. *Se $x \geq m$:*
$$P(\overline{X}_n \geq x) \leq e^{-n\lambda_\mu(x)}.$$

2. *Se $x \leq m$*
$$P(\overline{X}_n \leq x) \leq e^{-n\lambda_\mu(x)}.$$

(b) *$\forall x \in \mathbb{R}$:*

$$\liminf_{n\to\infty}\frac{1}{n}\log P(\overline{X}_n \geq x) \geq -\lambda_\mu(x),$$
$$\liminf_{n\to\infty}\frac{1}{n}\log P(\overline{X}_n \leq x) \geq -\lambda_\mu(x).$$

Uma prova do teorema pode ser encontrada em [36]. Chamamos a transformação $\log\hat{\mu}$ da lei comum μ de log-momento gerador da lei comum. A função λ_μ é chamada de função taxa (em geral usamos a notação $\lambda = I$).

Para fazer a extensão precisamos provar dois teoremas : o da extensão propriamente dita e a identificação da função taxa com a transformada de Legendre do log-momento gerador da lei comum das v.a.'s.
Neste contexto tomaremos uma sequência de variáveis aleatórias i.i.d.'s $\{X_n\}_{n\in\mathbb{N}}$ em $\mathbb{R}^d$, ou seja, ao invés de serem isomorfismos entre o espaço mensurável $\{\Omega, \mathscr{F}\}$ e $\{\mathbb{R}, \mathcal{B}(\mathbb{R})\}$ é um isomorfismo entre aquele e $\{\mathbb{R}^d, \mathcal{B}(\mathbb{R}^d)\}$. Chamaremos de μ a lei comum das v.a.'s X_n e $\overline{X}_n := 1/n\sum_{i=1}^{n} X_i$. Queremos provar dois lemas auxiliares e dois teoremas, que enunciaremos a seguir, junto com as definições que se fazem necessárias. As provas são adiadas para o apêndice (A).

Lema 1.1. *Sejam $C \in \mathbb{R}^d$ um convexo e*

$$l(C) := \lim_{n\to\infty} \frac{1}{n} \log P(\overline{X}_n \in C), \tag{1}$$

então, $l(C)$ existe em $[-\infty, 0]$ e

$$l(C) = \sup_n \frac{1}{n} \log P(\overline{X}_n \in C).$$

Definição 1.1. *Definimos a função $\lambda : \mathbb{R}^d \to [0, \infty]$*

$$\begin{aligned} \lambda(x) := -\inf\{l(C) \ : \ C \text{ vizinhança aberta e convexa de } x\} = \\ = \sup\{-l(C) \ : \ C \text{ vizinhança aberta e convexa de } x\} \end{aligned} \tag{2}$$

Lema 1.2. *A função λ definida acima é convexa e inferiormente semicontínua.*

Definição 1.2. *Seja $A \in \mathcal{B}(\mathbb{R}^d)$. Definimos*

$$\underline{l}(A) = \liminf_{n\to\infty} \frac{1}{n} P(\overline{X}_n \in A),$$

$$\bar{l}(A) = \limsup_{n\to\infty} \frac{1}{n} P(\overline{X}_n \in A).$$

E se $\underline{l}(A) = \bar{l}(A) = l(A)$. Definimos ainda,

$$\Lambda(A) := \inf_{x\in A} \lambda(x). \tag{3}$$

Teorema 1.2. *Sejam $A \in \mathcal{B}(\mathbb{R}^d)$, A° seu interior e $\bar{A}$ seu fecho. Valem :*

(i) $-\Lambda(A^\circ) \leq \underline{l}(A)$;

(ii) Se $\bar{A}$ for compacto, $\bar{l}(A) \leq -\Lambda(\bar{A})$;

(iii) Se $\bar{A}$ for compacto e $\Lambda(A^\circ) = \Lambda(\bar{A})$, então, $l(A)$ existe e $l(A) = -\Lambda(A)$;

(iv) Se A for a união finita de abertos convexos, então, $l(A)$ existe e $l(A) = -\Lambda(A)$.

Finalmente o teorema que nos diz como calcular λ :

Teorema 1.3. *Seja μ uma probabilidade em $\mathbb{R}^d$ e $\hat{\mu} : \mathbb{R}^d \to (0, \infty]$ sua transformada de Laplace :*

$$\hat{\mu}(t) := \int_{\mathbb{R}^d} e^{t \cdot x} \mu(dx), \quad x, t \in \mathbb{R}^d.$$

Se $\int |x| \mu(dx) < \infty$, então o λ definido em (2) *é dado por*

$$\lambda(x) = \sup_{t \in \mathbb{R}^d} \{t \cdot x - \log \hat{\mu}(t)\} \tag{4}$$

2 Principio de Grandes Desvios

O teorema de Cramèr-Chernoff serve como base para uma definição que se provou muito frutífera, a saber, a da condição ou principio *de grandes desvios*, que é a seguinte:

Definição 2.1. *Seja E um espaço métrico completo e separável e $\{P_n\}$ uma sequência de medidas de probabilidades na σ-álgebra de Borel $\mathcal{B}(E)$.*
Dizemos que $\{P_n\}$ ***satisfaz o principio de grandes desvios*** *com a função taxa $I : E \to [0, \infty]$ se:*

(i) $I : E \to [0, \infty]$ for inferiormente semicontínua;

(ii) valem:

$$\liminf_{n\to\infty} \frac{1}{n} \log P_n(A) \geq -\inf_{x\in A} I(x), \quad \textit{para todo aberto } A \subseteq E,$$

$$\limsup_{n\to\infty} \frac{1}{n} \log P_n(B) \leq -\inf_{x\in B} I(x), \quad \textit{para todo fechado } B \subseteq E.$$

Ou, de forma equivalente, definimos o principio para sequências de v.a.:

Definição 2.2. *Seja E um espaço métrico completo e separável e uma sequência de v.a.'s $\{X_n\}$. Dizemos que $\{X_n\}$* ***satisfaz o principio de grandes desvios*** *com a função taxa $I : E \to [0, \infty]$ se:*

(i) $I : E \to [0, \infty]$ for inferiormente semicontínua;

(ii) valem:

$$\liminf_{n\to\infty} \frac{1}{n} \log P(X_n \in A) \geq -\inf_{x\in A} I(x), \quad \textit{para todo aberto } A \subseteq E,$$

$$\limsup_{n\to\infty} \frac{1}{n} \log P(X_n \in B) \leq -\inf_{x\in B} I(x), \quad \textit{para todo fechado } B \subseteq E.$$

Além disso temos a seguinte caracterização da função taxa:

Definição 2.3. *Dizemos que a função taxa I é* ***boa*** *se para cada $a \in [0, \infty)$ o conjunto $\{x \in E \,:\, I(x) \leq a\}$ for compacto.*

O método usual de se abordar grandes desvios (doravante gd ou, usando a abreviação Inglesa mais comum, «*ldp*,» *large deviation principle*)—usado nos trabalhos clássicos de Freidlin & Wentzell, Varadhan, et. al.—é usando técnicas de mudança de medida: muda-se a medida para uma onde a probabilidade dos eventos raros, na medida original, é alta e um controle explicito é feito através das derivadas de Radon-Nikodym.

A abordagem feita por [17] utilizada em [28] e [1], por outro lado, olha processos de Markov e a convergência, em certo sentido, de seu gerador. Nesta abordagem podemos fazer uma conexão com a teoria de equações—e de fato, as equações obtidas e que devem satisfazer certas condições para se provar o *ldp* será do tipo Hamilton-Jacobi e, em diversas situações, a Hamiltoniana poderá ser escrita em forma variacional, dando origem a um problema de controle com um certo ganho. A seguir daremos detalhes dessa abordagem:

Seja $\{X_n\}_{n\in\mathbb{N}}$ uma sequência de processos de Markov X_n com valores em E (novamente, um espaço métrico completo e separável) com gerador A_n. Definimos o grupo semilinear de Markov $\{T_n(t)\}_{t\geq 0}$ através de:

$$\big(T_n(t)f\big)(x) = \mathbb{E}\Big(f(X_n(t))\Big|X_n(0) = x\Big), \;\; t \geq 0, \; x \in E.$$

Este semigrupo satisfaz, formalmente, a seguinte equação:

$$\frac{d}{dt}T_n(t)f = A_nT_n(t)f, \quad T_n(0)f = f.$$

Introduzindo o semigrupo não-linear $\{V_n(t)\}_{t\geq 0}$ para o processo de Markov X_n:

$$\big(V_n(t)f\big)(x) = \frac{1}{n}\log \mathbb{E}\Big(e^{nf(X_n(t))}\Big|X_n(0) = x\Big), \;\; t \geq 0, \; x \in E,$$

que satisfaz, formalmente:

$$\frac{d}{dt}V_n(t)f = H_nV_n(t)f,$$

onde H_n é o gerador do semigrupo não-linear $\{V_n(t)\}_t$, definido como:

$$H_nf := \frac{1}{n}\mathcal{H}_n(nf) = \frac{1}{n}e^{-nf}A_ne^{nf}.$$

Desde Felming em 1985 [10] foi provado o *ldp* para cadeias de Markov em tempo fixo através do estudo da convergência do semi-grupo não-linear acima. Esse é um processo um tanto natural para se investigar GD, tendo em vista o seguinte resultado:

Lema 2.1. *Uma sequência de v.a.'s $\{X_n\}_n$ converge em distribuição*[2] *para X se, e somente se,*

$$\liminf_{n\to\infty} P(X_n \in A) \geq P(X \in A), \;\; \textit{para todo aberto } A,$$

ou

$$\limsup_{n\to\infty} P(X_n \in B) \leq P(X \in B), \;\; \textit{para todo fechado } B.$$

Feng & Kurtz [17] utilizaram essas ideias e generalizaram o resultado: mostrando a convergência do semi-grupo não linear $V_n(t)$ e seus geradores H_n podemos garantir o *ldp* para a sequência de cadeias de Markov $\{X_n\}_n$, através dos seguintes passos delineados por Adams em [1]:

[2] I.e. $\{X_n\}$ converge em distribuição para X se, e somente se,

$$\lim_{n\to\infty} \mathbb{E}(f(X_n)) = \mathbb{E}(f(X)),$$

para cada função limitada e contínua em E.

1. ***Convergência de*** $\{H_n\}_{n\in\mathbb{N}}$: Devemos garantir a convergência da sequência de geradores do semi-grupo não-linear à algum operador H: para cada f no domínio de H, i.e., $f \in \mathcal{D}(H)$, existe uma sequência $f_n \in \mathcal{D}(H_n)$ tal que, em certo sentido,
$$f_n \to f, \quad H_n f_n \to Hf,$$
à medida que $n \to \infty$.

   Uma questão implícita na investigação de grandes desvios é a questão da estreiteza exponencial (ou *exponential tightness*): dizemos que uma sequência de medidas de probabilidade $\{P_n\}_n$ em E é «***estreita exponencialmente***» se $\forall \alpha > 0$, $\exists K_\alpha \subset E$, K_α compacto, tal que
$$\limsup_{n\to\infty} \frac{1}{n} \log P_n(K_\alpha^c) < -\alpha,$$
e uma sequência de v.a.'s $\{X_n\}_n$ em E é estreita exponencialmente se a sequência de distribuições induzidas por $\{X_n\}$ for estreita exponencialmente. Essa definição é importante pois se $\{P_n\}_n$ satisfaz o *ldp* com uma função taxa boa I então $\{P_n\}_n$ é estreita exponencialmente. E, por outro lado, segundo Puhalskii em [37] se $\{P_n\}_n$ for estreita e exponencialmente estreita, então existe uma subsequência $\{P_{n_k}\}_{k\in\mathbb{N}}$ que satisfaz o *ldp*.

   A estreiteza exponencial é um passo importante para a abordagem de Feng & Kurtz e, em geral, ela é garantida pela convergência dos geradores $\{H_n\}$— para mais detalhes, vide [17].

2. ***Propriedades de*** H: Tendo garantido a convergência precisamos garantir algumas propriedades do operador limite H da sequência $\{H_n\}$, e há duas alternativas para esse processo, viz., garantir uma *range condition* ou um *principio de comparação*. Aquela condição é mais difícil de se garantir na maioria dos casos, ao passo que esta não é tanto; então, enunciaremos apenas o principio de comparação, deixando como referência para a condição sobre o alcance [1] e [17].

O Principio de Comparação A *range condition* requer, essencialmente, que a equação
$$(\mathbb{1} - \alpha H)f = h \tag{5}$$

tenha soluções[3] $f \in D(H)$ para uma classe suficientemente grande de $h \in D(H)$ e α suficientemente pequenos. A condição de comparação, por outro lado, enfraquece os requerimentos exigindo apenas que soluções mais fracas (viz. soluções viscosas) se relacionem de certo modo.
Antes de enunciar o principio precisamos de algumas definições:

Definição 2.4. *Seja uma função f. Definimos sua* ***regularização superiormente semicontínua*** *como sendo a função f^* dada por*

$$f^*(x) = \limsup_{y \to x} f(y).$$

Analogamente, definimos sua ***regularização inferiormente semicontínua*** *como sendo a função f_* dada por*

$$f_* = \liminf_{y \to x} f(y).$$

Definição 2.5. *Sejam E um espaço métrico compacto e o operador[4] $H \subset C(E) \times \mathcal{B}(E)$. Fixando $h \in C(E)$ e $\alpha > 0$, seja $f \in \mathcal{B}(E)$ e definimos*

$$g := \alpha^{-1}(f - h), \;\; \textit{i.e.}, \;\; f - \alpha g = h.$$

Então, dizemos que f é uma ***sub-solução viscosa*** *de* (5) *se, e somente se, para cada $(f_0, g_0) \in H$ tal que*

$$\sup_x \{f(x) - f(x_0)\} = \|f - f_0\|$$

existe um $x_0 \in E$ que satisfaz:

$$\sup_x \{f(x) - f(x_0)\} = (f - f_0)(x_0)$$

e

$$g(x_0) \leq (g_0)^*(x_0).$$

Dizemos que f é uma ***super-solução viscosa*** *de* (5) *se, e somente se, para cada $(f_0, g_0) \in H$ tal que*

$$\sup_x \{f(x) - f(x_0)\} = \|f - f_0\|$$

[3]Usamos a notação $D(H)$ para o domínio de H.
[4]Aqui estamos definindo H através de seu gráfico.

existe um $x_0 \in E$ *que satisfaz:*

$$\sup_x \{f(x) - f(x_0)\} = (f - f_0)(x_0)$$

e

$$g(x_0) \leq (g_0)_*(x_0).$$

Por fim, f *é uma* ***solução viscosa*** *de* (5) *se* f *for uma sub-solução e uma super-solução viscosa.*

Agora podemos enunciar o principio de comparação:

Definição 2.6. *Dizemos que a equação* (5) *satisfaz o* ***principio de comparação*** *se a equação admite uma sub-solução viscosa* v *e uma super-solução viscosa* u *tais que*

$$u \leq v.$$

A abordagem via convergência de semi-grupos não-lineares (novamente, vide [17] e [1]) nos garante que uma sequência de processos de Markov $\{X_n\}_{n\in\mathbb{N}}$ com geradores A_n satisfaz o principio de grandes desvios como enunciado acima se H_n, como definido acima, convergir para H e se H satisfizer o principio de comparação.

Para deixar este método mais claro vamos delinear como R. Kraaij em [28] o utilizou para investigar dois processos. Nos focaremos aqui em um dos processos—por ser o processo que mais nos interessa.

Consideramos n cópias de um processo de Markov em $A = \{1, \ldots, d\}$ (no contexto de [24] chamamos este conjunto de uma coleção de *classical label*): seja $\sigma(t)$ a cadeia de Markov à tempo contínuo em A com uma certa taxa de transição—i.e., a função $t \mapsto \sigma(t) \in A$ segue a evolução de um spin. Fazemos n cópias independentes desse processo $\sigma^n(t) = (\sigma_1(t), \ldots, \sigma_n(t)) \in A^n$, e consideramos a evolução da medida empírica dessas cópias:

$$\mu_n(t) := \frac{1}{n}\sum_{i=1}^{n} \delta_{\sigma_i(t)} \in \Delta_d^n =: E$$

onde $\Delta_d^n = \Delta_d \cap \frac{1}{n}\mathbb{Z}^d$ e onde Δ_d é um simplex em $\mathbb{R}^d$.
O gerador do processo de Markov $\mu(t) = \mu_n(t) \in \Delta_d^n$ é dado por

$$A_n f(\mu) = n \sum_{a,b} \mu_a r_n(a,b) \Big[f\Big(\mu + \frac{\delta_b - \delta_a}{n}\Big) - f(\mu) \Big],$$

onde r_n é uma função que representa uma taxa de transição.

Em [28] foi provado que para funções taxas r_n que respeitam algumas condições μ_n, que são elementos do espaço de Skorokhod $D_E[0,\infty)$, satisfazem o principio de grandes desvios, i.e., há uma função $I : D_E[0,\infty) \to [0,\infty]$ inferiormente semicontínua tal que:

(i) para todo conjunto aberto $A \subseteq D_E[0,\infty)$

$$\liminf_{n\to\infty} \frac{1}{n} \log P\Big(\{\mu_n(t)\}_{t\geq 0} \in A \Big) \geq - \inf_{\gamma \in A} I(\gamma)$$

(ii) para todo fechado $B \subseteq D_E[0,\infty)$

$$\limsup_{n\to\infty} \frac{1}{n} \log P\Big(\{\mu_n(t)\}_{t\geq 0} \in B \Big) \leq - \inf_{\gamma \in B} I(\gamma).$$

Isso é provado através da investigação do limite de

$$H_n f := \frac{1}{n} e^{-nf} A_n e^{nf}$$

que converge para H, dado por $(Hf)(\mu) = H(\mu, \nabla f(\mu))$, onde

$$H(\mu, p) = \sum_{a,b} v(a,b,\mu) \big(e^{p_b - p_a} - 1 \big),$$

onde v é uma função adequada (para detalhes vide [28]).

Para H da forma $Hf(x) = H(x, \nabla f(x))$ re-enunciamos o principio da comparação da seguinte forma:

Seja $H : E \times \mathbb{R}^d \to \mathbb{R}$, onde E é um espaço normado compacto, definimos soluções viscosas da equação de Hamilton-Jacobi

$$\varphi(x) - \lambda H(x, (\nabla\varphi)(x)) - h(x) = 0, \tag{6}$$

onde $h \in C(E)$, $\varphi \in C^1(E)$ e $\lambda > 0$ através de:

Definição 2.7 (Solução Viscosa)**.** *Dizemos que u é uma* ***subsolução viscosa*** *de* (6) *se u for limitada, superiormente semicontínua e se para toda $\varphi \in C^1(E)$ e todo x_0 tal que $u - \varphi$ possui um máximo em x_0 temos*

$$u(x_0) - \lambda H(x_0, (\nabla\varphi)(x_0)) - h(x_0) \leq 0$$

Dizemos que v é uma ***supersolução viscosa*** *de* (6) *se v for limitada, inferiormente semicontínua e se para todo $\varphi \in C^1(E)$ e todo x_0 tal que $v - \varphi$ possui um mínimo em x_0 temos*

$$v(x_0) - \lambda H(x_0, (\nabla\varphi)(x_0)) - h(x_0) \leq 0$$

Uma ***solução viscosa*** *é uma tanto uma subsolução viscosa quanto uma supersolução viscosa.*

Definição 2.8. *Dizemos que a equação de Hamilton-Jacobi* (6) ***satisfaz o principio da comparação*** *se uma subsolução u e uma supersolução u se relacionam da seguinte forma:*

$$u \leq v.$$

Os seguintes teoremas de análise nos auxiliam na avaliação se, dado um Hamiltoniano H, (6) satisfaz o principio da comparação:

Lema 2.2. *Seja $E \subset \mathbb{R}^d$ compacto, $u, v : E \to \mathbb{R}$ duas funções superiormente semicontínua (u) e inferiormente semicontínua (v). Seja $\psi : E \times E \to \mathbb{R}^+$ inferiormente semicontínua e tal que $\psi(x, y) = 0 \;\Leftrightarrow\; x = y$. Por fim, seja $\alpha > 0$ e $x_\alpha, y_\alpha \in E$ tais que*

$$u(x_\alpha) - v(y_\alpha) - \alpha\psi(x_\alpha, y_\alpha) = \sup_{x,y\in E}\Big\{u(x) - v(x) - \alpha\psi(x, y)\Big\}.$$

Então:

(i) $\lim_{\alpha\to\infty} \alpha\psi(x_\alpha, y_\alpha) = 0$*;*

(ii) Os pontos de acumulação de (x_α, y_α) são (z, z), onde z é tal que

$$u(z) - v(z) = sup_{x\in E}\Big\{u(x) - v(x)\Big\}.$$

Dizemos que o ψ que satisfaz as condições do lema acima e que seja diferenciável e que

$$\Big(\nabla\psi(.,y)\Big)(x) = -\Big(\nabla\psi(x,.)\Big)(y)$$

de uma ***função de penalização boa***. O seguinte teorema nos garante uma condição suficiente para que (6) satisfaça o principio da comparação:

Teorema 2.1. *Seja H um operador com domínio $D(H) = C^1(E)$ da forma $(Hf)(x) = H(x,(\nabla f)(x))$ e sejam u e v respectivamente uma subsolução e uma supersolução viscosa de* (6)*. Sejam ψ uma função de penalização boa e α e (x_α, y_α) que satisfazem as hipóteses do lema* (2.2) *acima. Então:*

$$\sup_\alpha H\Big(y_\alpha, \alpha(\nabla_x\psi)(x_\alpha,y_\alpha)\Big) < \infty. \tag{7}$$

E se o hamiltoniano satisfaz

$$\liminf_{\alpha\to\infty}\Big\{H\Big(x_\alpha, \alpha(\nabla_x\psi)(x_\alpha,y_\alpha)\Big) - H\Big(y_\alpha, \alpha(\nabla_x\psi)(x_\alpha,y_\alpha)\Big)\Big\} \leq 0, \tag{8}$$

então,

$$u \leq v.$$

Demonstração. Comecemos a provar (7): fixamos λ e h temos

$$\begin{aligned} u(x_\alpha) - v(y_\alpha) - \alpha\psi(x_\alpha,y_\alpha) &= \sup_{x,y\in E}\Big\{u(x) - v(y) - \alpha\psi(x,y)\Big\} = \\ &= \sup_{x,y\in E}\Big\{(-1)(v(y) - (u(x) - \alpha\psi(x,y)))\Big\} = \\ &= -\inf_{x,y\in E}\Big\{v(y) - (u(x) - \alpha\psi(x,y))\Big\} \end{aligned}$$

assim,

$$\begin{aligned} v(y_\alpha) - (u(x_\alpha) - \alpha\psi(x_\alpha,y_\alpha)) &= \inf_{x,y\in E}\Big\{v(y) - (u(x) - \alpha\psi(x,y))\Big\} \\ &= \inf_{y\in E}\Big\{v(y) - (u(x_\alpha) - \alpha\psi(x_\alpha,y))\Big\}. \end{aligned}$$

Tomamos

$$f(y) := u(x_\alpha) - \alpha\psi(x_\alpha,y),$$

e temos que $v - f$ atinge um mínimo em y_α e como v é uma supersolução viscosa:

$$v(y_\alpha) - \lambda H(y_\alpha, (\nabla f)(y_\alpha)) - h(y_\alpha) \geq 0,$$

onde $(\nabla f)(y_\alpha) = -\alpha(\nabla\psi(x_\alpha, .))(y_\alpha) = \alpha(\nabla\psi(., y_\alpha))(x_\alpha) = \alpha(\nabla_x\psi)(x_\alpha, y_\alpha)$— usamos aqui o fato de ψ ser uma função de penalização boa. Então,

$$H\Big(y_\alpha, \alpha(\nabla_x\psi)(x_\alpha, y_\alpha)\Big) \leq \frac{1}{\lambda}\Big(v(y_\alpha) - h(y_\alpha)\Big)$$

Então,

$$\sup_\alpha H\Big(y_\alpha, \alpha(\nabla_x\psi)(x_\alpha, y_\alpha)\Big) \leq \frac{1}{\lambda}\|v - h\| \leq \infty.$$

Provemos agora que (8) implica que $u \leq v$: suponha por absurdo que $\delta := \sup_{x\in E}\{u(x) - v(x)\} > 0$. Tomamos ψ e (x_α, y_α) conforme as hipóteses, então,

$$\lim_{\alpha\to\infty} \alpha\psi(x_\alpha, y_\alpha) = 0$$

e z é um limite de x_α e y_α. Segue que para um α suficientemente grande,

$$u(x_\alpha) - v(x_\alpha) \geq \frac{1}{2}\delta.$$

Tomamos novamente $f(y) = u(x_\alpha) - \alpha\psi(x_\alpha, y)$ e definimos $g(x) := v(y_\alpha) + \alpha\psi(x, y_\alpha)$. Então, $u - g$ atinge um máximo em x_α e $v - f$ um mínimo em y_α. Portanto,

$$u(x_\alpha) - \lambda H(x_\alpha, \alpha(\nabla_x\psi)(x_\alpha, y_\alpha)) - h(x_\alpha) \leq 0,$$
$$v(y_\alpha) - \lambda H(y_\alpha, \alpha(\nabla_x\psi)(x_\alpha, y_\alpha)) - h(y_\alpha) \leq 0,$$

onde já lançamos mão de ψ ser função de penalização boa. Então, para α suficientemente grande,

$$\frac{1}{\lambda}(u(x_\alpha) - h(x_\alpha)) - \frac{1}{\lambda}(v(y_\alpha) - h(y_\alpha)) + \overbrace{\frac{1}{\lambda}(h(x_\alpha) - h(y_\alpha))}^{=:\varepsilon_\alpha} =$$
$$= \frac{1}{\lambda}(u(x_\alpha) - v(y_\alpha) \geq \frac{\delta}{2\lambda}$$

Por outro lado, o lado esquerdo é menor ou igual à

$$H(x_\alpha, \alpha(\nabla_x\psi)(x_\alpha, y_\alpha)) - H(y_\alpha, \alpha(\nabla_x\psi)(x_\alpha, y_\alpha)) + \varepsilon_\alpha.$$

Pela continuidade de h, ε_α vai à zero a medida que $\alpha \to \infty$. Chegamos, então, à desigualdade

$$\liminf_{\alpha\to\infty}\Big\{H\Big(x_\alpha, \alpha(\nabla_x\psi)(x_\alpha, y_\alpha)\Big) - H\Big(y_\alpha, \alpha(\nabla_x\psi)(x_\alpha, y_\alpha)\Big)\Big\} \geq \frac{\delta}{2\lambda} > 0,$$

o que contradiz a hipótese (8). Então $u \leq v$. $\square$

A condição (8) nos garante que a equação de Hamilton-Jacobi satisfaz o principio de comparação e a desigualdade (7) nos dá um certo controle sobre as sequências x_α e y_α, o que é crucial na verificação de (8).

Por fim, para provar o *ldp* para $\{\mu_n\}$ é necessário, apenas, escolher uma função taxa r_n adequada, o que é feito em [28].

A Extensão do Teorema de Cramèr-Chernoff

A.1 Prova do Lema (1.1)

Demonstração. Para provar este lema basta provar (vide [2]) que

$$f(n) := \log P(\overline{X}_n \in C),$$

onde $C \subseteq \mathbb{R}^d$ é um conjunto convexo, é superaditiva, i.e.,

$$f(n+m) \geq f(n) + f(m).$$

Para tal, notamos que como $\{X_n\}$ são v.a.'s i.i.d podemos escrever

$$P(\overline{X}_n \in C)P(\overline{X}_m \in C) = P\Big(\frac{X_1 + \cdots + X_n}{n} \in C\Big)P\Big(\frac{X_{n+1} + \cdots + X_{n+m}}{m}\Big)$$

$$= P\Big(\frac{X_1 + \cdots + X_n}{n} \in C,\ \frac{X_{n+1} + \cdots + X_{n+m}}{m}\Big) \leq P(\overline{X}_{n+m} \in C),$$

já que C é convexo e

$$\overline{X}_{n+m} = \frac{n}{n+m}\Big(\frac{X_1 + \cdots + X_n}{n}\Big) + \frac{m}{n+m}\Big(\frac{X_{n+1} + \cdots + X_{n+m}}{m}\Big),$$

e isso completa a prova. □

A.2 Prova do Lema (1.2)

Demonstração. Que λ_μ é inferiormente semicontínua: seja $x \in \mathbb{R}^d$. Então, $\forall \varepsilon > 0$, $\exists C$ vizinhança aberta e convexa de x tal que

$$-l(C) > \lambda_\mu(x) - \varepsilon.$$

Por outro lado, para $y \in C$,

$$\lambda_\mu(y) \geq -l(C).$$

Assim,

$$\lambda_\mu(x) - \varepsilon < -l(C) \leq \lambda_\mu(y),$$

ou seja, $\lambda_\mu(x) - \varepsilon < \liminf_{y \to x} \lambda_\mu(y)$. Como ε é arbitrário,

$$\liminf_{y \to x} \lambda_\mu(y) \geq \lambda_\mu(x),$$

o que prova que λ_μ é inferiormente semicontínua.
Para provar que λ_μ é convexa lançamos mão de um resultado de análise que nos diz que: se uma função $f : I \to \mathbb{R}$ for inferiormente semicontínua e satisfizer

$$f\Big(\frac{x+y}{2}\Big) \leq \frac{1}{2}\Big(f(x) + f(y)\Big),$$

então f é convexa. Basta, assim, mostrar que

$$\lambda_\mu\Big(\frac{x+y}{2}\Big) \leq \frac{1}{2}\Big(\lambda_\mu(x) + \lambda_\mu(y)\Big).$$

Para provar isso basta mostrarmos que se C é um aberto e convexo tal que $(x+y)/2 \in C$, então existem dois abertos e convexos C_1 e C_2 tais que $x \in C_1$ e $y \in C_2$ e vale:

$$-l(C) \leq -\frac{1}{2}\Big(l(C_1) + l(C_2)\Big),$$

pois desta forma teríamos:

$$-l(C) \leq \frac{1}{2}\Big(\lambda_\mu(x) + \lambda_\mu(y)\Big) \;\Rightarrow\; \lambda_\mu\Big(\frac{x+y}{2}\Big) \leq \frac{1}{2}\Big(\lambda_\mu(x) + \lambda_\mu(y)\Big).$$

Para isso seja C tal que $(x+y)/2 \in C$. Então, existe C_1 e C_2 com $x \in C_1$, $y \in C_2$ tais que

$$\frac{1}{2}(C_1 + C_2) := \Big\{\frac{z+w}{2} \;:\; z \in C_1,\; w \in C_2\Big\} \subseteq C.$$

Para verificar isso tomamos $C_1 = B_\delta(x)$ e $C_2 = B_\delta(y)$—ou seja, bolas abertas em $\mathbb{R}^d$ de raio δ e centros x e y.
Então, $|z-x| < \delta$ e $|w-y| < \delta$. Portanto:

$$\Big|\frac{z+w}{2} - \frac{x+y}{2}\Big| = \Big|\frac{z-x}{2} + \frac{w-y}{2}\Big| \leq \frac{1}{2}\Big(|z-x| + |w-y|\Big) < \delta$$

$$\Rightarrow\; \frac{z+w}{2} \in C \;\Rightarrow\; \frac{1}{2}(C_1 + C_2) \in C.$$

Deste modo,

$$\Big\{\frac{X_1 + \cdots + X_n}{n} \in C_1\Big\} \cap \Big\{\frac{X_{n+1} + \cdots + X_{2n}}{n} \in C_2\Big\} \subseteq \Big\{\frac{X_1 + \cdots + X_{2n}}{2n} \in C\Big\}.$$

Portanto,

$$P(\overline{X}_n \in C_1)P(\overline{X}_n \in C_2) \leq P(\overline{X}_{2n} \in C)$$

$$\therefore\; \frac{1}{2}\Big(\frac{1}{n}\log P(\overline{X}_n \in C_1) + \frac{1}{n}\log P(\overline{X}_n \in C_2)\Big) \leq \frac{1}{2n}\log P(\overline{X}_{2n} \in C)$$

$$\therefore\; \frac{1}{2}\Big(-l(C_1) - l(C_2)\Big) \geq -l(C) \;\;\therefore\; \frac{1}{2}\Big(\lambda_\mu(x) + \lambda_\mu(y)\Big) \geq -l(C),$$

para todo $C \ni (x+y)/2$ aberto e convexo. Então,

$$\lambda_\mu\Big(\frac{x+y}{2}\Big) \leq \frac{1}{2}\Big(\lambda_\mu(x) + \lambda_\mu(y)\Big).$$

$\square$

A.3 Prova do Teorema (1.2)

Demonstração. (*i*) Se A não for aberto, A° é aberto e $A^\circ \subset A$ e $\underline{l}(A^\circ) \leq \underline{l}(A)$. Se conseguirmos estabelecer que $-\Lambda(A^\circ) \leq \underline{l}(A^\circ)$ seguirá que

$$-\Lambda(A^\circ) \leq \underline{l}(A).$$

Assim, basta provar o teorema para A aberto, i.e., $A^\circ = A$.
Se A for aberto, $\exists \delta > 0$ tal que $B_\delta(x) \subseteq A$, para um $x \in A$ fixo. Como $B_\delta(x)$ é convexo e aberto pelo (1.1) o limite $l(B_\delta(x))$ existe. Assim:

$$-\lambda_\mu(x) = \inf\Big\{l(C) \,:\, C \ni x \text{ aberto e convexo}\Big\} \leq l(B_\delta(x)) = \underline{l}(B_\delta(x)) \leq \underline{l}(A),$$

já que $B_\delta(x) \subseteq A$. Ou seja,

$$-\lambda_\mu(x) \leq \underline{l}(A), \;\; \forall x \in A.$$

$$\therefore \;\; \sup_x\{-\lambda_\mu(x)\} \leq \underline{l}(A) \;\;\; \therefore \;\; -\inf_x\{\lambda_\mu(x)\} \leq \underline{l}(A),$$

como queríamos provar.

(*ii*) Notamos que $A \subset \overline{A}$ e, portanto, $\overline{l}(A) \leq \overline{l}(\overline{A})$, assim, se conseguirmos estabelecer que

$$\overline{l}(\overline{A}) \leq -\Lambda(\overline{A})$$

teremos que $\overline{l}(A) \leq -\Lambda(\overline{A})$. Basta, então, mostrar o teorema para o caso $A = \overline{A}$: A fechado e compacto (por hipótese).
Seja, então,

$$a > -\inf_{x\in A} \lambda_\mu(x) = \sup_{x\in A} \inf_{C\ni x}\{l(C)\}.$$

Então, para cada $x \in A$, existe uma vizinhança aberta e convexa C_x de x tal que $a > l(C_x)$.
Por outro lado, $A \subseteq \bigcup_{x\in A} C_x$. Como A é compacto há uma subcobertura finita de A: $x_1, \ldots, x_m \in A$ com

$$A \subseteq \bigcup_{i=1}^{m} C_{x_i}.$$

Como cada um dos C_{x_i} são abertos e convexos, pelo lema (1.1) existe o limite $l(C_{x_i}) = \underline{l}(C_{x_i})$. Então,

$$\overline{l}(A) \leq \overbrace{\overline{l}(\bigcup C_{x_i}) \leq \max_{i=1,\ldots,m} l(C_{x_i})}^{*} < a.$$

Logo provaremos (*), mas por hora assumindo sua veracidade temos, resumindo:

$$\bar{l}(A) < a, \qquad -\inf_x \lambda_\mu(x) < a.$$

Suponha, por absurdo, que $-\inf_x \lambda_\mu(x) < \max_i l(C_{x_i})$. Como a é arbitrário podemos tomá-lo como sendo

$$-\inf_x \lambda_\mu(x) < a \leq \max_i l(C_{x_i}),$$

o que contradiz a desigualdade acima. Então, $-\inf_x \lambda_\mu(x) \geq \max_i l(C_{x_i})$. Portanto,

$$\bar{l}(A) \leq \max_i l(C_{x_i}) \leq -\inf_x \lambda_\mu(x),$$

como desejávamos. Resta-nos agora provar (*), que se reduz à provar que

$$\bar{l}(A \cup B) \leq \max\{\bar{l}(A), \bar{l}(B)\}.$$

Seja um c arbitrário tal que

$$c > \max\{\bar{l}(A), \bar{l}(B)\}.$$

Em particular,

$$c > \bar{l}(A) = \inf_{n\in\mathbb{N}} \sup_{k\geq n} \frac{1}{k} \log P(\overline{X}_k \in A).$$

Então, existe um n_0 natural tal que

$$c > \sup_{k\geq n_0} \frac{1}{k} \log P(\overline{X}_k \in A) > \frac{1}{k} \log P(\overline{X}_k \in A), \ \ \forall k \geq n_0.$$

$$\Rightarrow \ \ e^{ck} > P(\overline{X}_k \in A), \ \forall k \geq n_0.$$

Da mesma forma existe um m_0 tal que

$$e^{ck} > P(\overline{X}_k \in B), \ \forall k \geq m_0,$$

e então para um k suficientemente grande:

$$P(\overline{X}_k \in A \cup B) \leq P(\overline{X}_k \in A) + P(\overline{X}_k \in B) < 2e^{ck},$$

portanto, $\bar{l}(A \cup B) \leq c$.
Caso $\max\{\bar{l}(A), \bar{l}(B)\} < \bar{l}(A \cup B)$, como c é arbitrário, poderíamos tomá-lo como

$$\max\{\bar{l}(A), \bar{l}(B)\} < c < \bar{l}(A \cup B),$$

o que contradiz o resultado acima, viz., $\bar{l}(A \cup B) \leq c$. Logo $\bar{l}(A \cup B) \leq \max\{\bar{l}(A), \bar{l}(B)\}$.

(*iii*) Por definição sabemos que $\underline{l}(A) \leq \bar{l}(A)$, e por (*i*) e (*ii*):

$$-\Lambda(A^\circ) \leq \underline{l}(A) \leq \bar{l}(A) \leq -\Lambda(\bar{A}),$$

e como os extremos são iguais, por hipótese, $\underline{l}(A)$ e $\bar{l}(A)$ são iguais à $-\Lambda(A^\circ) = -\Lambda(\bar{A})$, e pela definição de Λ, $\Lambda(A^\circ) = \Lambda(\bar{A}) \Rightarrow \Lambda(\bar{A}) = \Lambda(A)$.

(*iv*) Sejam C_i, $i = 1, \ldots, m$ os abertos convexos que formam A :

$$A = \bigcup_{i=1}^{m} C_i.$$

É evidente que, para $A, B \in \mathcal{B}(\mathbb{R}^d)$, $\underline{l}(A) \leq \underline{l}(A \cup B)$ e $\underline{l}(B) \leq \underline{l}(A \cup B)$, e, assim, $\underline{l}(A \cup B) \geq \max\{\underline{l}(A), \underline{l}(B)\}$. E junto com o que foi provado acima :

$$\max_i \Big\{\underline{l}(C_i)\Big\} \leq \underline{l}\Big(\bigcup_i C_i\Big) \leq \bar{l}\Big(\bigcup_i C_i\Big) \leq \max_i \Big\{\bar{l}(C_i)\Big\}.$$

Pelo lema (1.1) existe $l(C_i)$, então os extremos da desigualdade acima são iguais e portanto existe $l(A) = l(\cup C_i)$, e, além disso, $l(A) = \max_i l(C_i)$. Queremos provar que $-\Lambda(A) = l(A)$. Mas pela definição de Λ:

$$\Lambda(A) = \min_i \Big\{\Lambda(C_i)\Big\}, \text{ i.e., } -\Lambda(A) = \max_i \Big\{-\Lambda(C_i)\Big\},$$

ou seja, devemos provar que :

$$-\Lambda(A) = \max_i \Big\{-\Lambda(C_i)\Big\} = l(A) = \max_i \Big\{l(C_i)\Big\},$$

o que será provado se conseguirmos mostrar que $l(C_i) = -\Lambda(C_i)$.
Se $l(C_i) = -\infty$ a igualdade segue, pois neste caso, $\lambda(x)$ será $+\infty$ e $\Lambda(C_i) = \infty$. Vamos assumir que $l(C_i) > \infty$.

De (*i*):

$$-\Lambda(C_i) \leq \underline{l}(C_i) = l(C_i).$$

Seja $\mu_n(C_i) := P(\overline{X}_n \in C_i)$. Pelo lema (1.1) o limite $\lim(1/n) \log \mu_n(C_i)$ existe e é igual à $l(C_i)$, i.e.,

$$\forall \varepsilon > 0,\ \exists n_\varepsilon > 0 \text{ tal que } \left|\frac{1}{n} \log \mu_n(C_i) - l(C_i)\right| < \varepsilon,\ \ \forall n \geq n_\varepsilon,$$

ou seja,

$$-\varepsilon < \frac{1}{n_\varepsilon} \log \mu_{n_\varepsilon}(C_i) - l(C_i) < \varepsilon \quad \therefore \quad \frac{1}{n_\varepsilon} \log \mu_{n_\varepsilon}(C_i) > l(C_i) - \varepsilon.$$

Por outro lado, há um lema de Deuschel e Stroock que nos diz que : sendo C_i aberto e convexo, então existe um $K_\varepsilon \subset C_i$ compacto e convexo tal que

$$\mu_{n_\varepsilon} \geq (1-\varepsilon)\mu_{n_\varepsilon}(C_i), \ \forall \varepsilon \in (0,1).$$

Assim,

$$\log \mu_{n_\varepsilon}(K_\varepsilon) \geq \log(1-\varepsilon) + \log \mu_{n_\varepsilon}(C_i) > n_\varepsilon \Big(l(C_i) - \varepsilon \Big).$$

Seja $f(n) := \log \mu_{n_\varepsilon}(K_\varepsilon)$. Como K_ε é convexo, pelo lema (1.1) $f(n+m) \geq f(m) + f(n)$, então,

$$f(mn_\varepsilon) \geq mf(n_\varepsilon) \geq mn_\varepsilon \Big(l(C_i) - \varepsilon \Big) + m \log(1-\varepsilon)$$

$$\therefore \quad \frac{f(mn_\varepsilon)}{mn_\varepsilon} \geq l(C_i) - \varepsilon + \frac{\log(1-\varepsilon)}{n_\varepsilon} = l(C_i) - \Big(\varepsilon + \frac{|\log(1-\varepsilon)|}{n_\varepsilon} \Big).$$

Mas, $f(mn_\varepsilon) = \log \mu_{mn_\varepsilon}(K_\varepsilon) = \log P(X_{mn_\varepsilon} \in K_\varepsilon)$, e então

$$l(K_\varepsilon) = \lim_{n \to \infty} \frac{f(mn_\varepsilon)}{mn_\varepsilon} \geq l(C_i) - \Big(\varepsilon + \frac{|\log(1-\varepsilon)|}{n_\varepsilon} \Big).$$

Tomando ε pequeno o suficiente e n_ε grande o suficiente o termo entre parenteses do lado direito da desigualdade acima tende à zero, donde concluímos que $l(K_\varepsilon) \geq l(C_i)$.
Mas $K_\varepsilon \subset C_i$ e então

$$\sup_{x \in C_i} \{-\lambda(x)\} \geq \sup_{x \in K_\varepsilon} \{-\lambda(x)\} \quad \Rightarrow \quad -\Lambda(C_i) \geq -\Lambda(K_\varepsilon).$$

Por (*ii*),

$$-\Lambda(K_\varepsilon) \geq l(K_\varepsilon),$$

e, portanto,

$$-\Lambda(C_i) \geq -\Lambda(K_\varepsilon) \geq l(K_\varepsilon) \geq l(C_i),$$

o que conclui a prova.

□

A.4 Prova do Teorema (1.3)

Demonstração. Provaremos apenas o caso para $d = 1$ e notamos que para $d > 1$ devemos apenas escrever $\lambda(x)$ como o supremo de $-l$ calculado em semiespaços abertos que contém x e então fazemos projeções em $\mathbb{R}$ e utilizamos o caso $d = 1$. Para os detalhes dessa prova e do que segue sugerimos a consulta à [36] e [21].

Caso d=1: Suponha, sem perda de generalidade, que $\mathbb{E}X_1 = 0$. Seja

$$\tilde{\lambda}(x) := \sup_{t\in\mathbb{R}}\{tx - \log\hat{\mu}(t)\}.$$

Assumiremos como sabido que: (*i*) $\tilde{\lambda}$ e λ são ambas convexas e inferiormente semicontínuas, tomando valores em $[0, \infty)$; (*ii*) $\tilde{\lambda}(0) = 0$. Mostraremos que λ também concorda com $\tilde{\lambda}$ em $x = 0$.
Escrevemos:

$$\lambda(x) = -\inf\{l(C) \ : \ C \ni x \text{ vizinhança aberta e convexa de } x\} = \\ = -\lim_{\varepsilon\to 0} l\big((x-\varepsilon, x+\varepsilon)\big).$$

Pela lei dos grandes números $P(|\overline{X}_n| \geq \varepsilon) \to 0$, então, $P(|\overline{X}_n| < \varepsilon) \to 1$, e assim, $l((-\varepsilon, \varepsilon)) = 0$, portanto, $\lambda(0) = 0$.

Feito isso observamos que: há um resultado de análise que garante que se $\tilde{\lambda}$ chegar ao infinito haverá um intervalo (r, p), $r \in (-\infty, 0]$ e $p \in [0, \infty)$ no qual $\tilde{\lambda}$ é finito e continuo, fora de (r, p) ele é infinito e é continuo à direita em r e à esquerda em p. Analogamente há um resultado para λ para um intervalo $[s, q]$ no qual ele é finito.
O restante da prova consiste em procurar relações entre $\tilde{\lambda}$ e λ que contradizem esse resultado acima se $\tilde{\lambda}$ e λ não coincidirem em todos os pontos.

O Teorema de Cramèr-Chernoff nos diz:

$$\text{para } x \leq m = 0 \ \ P(\overline{X}_n \leq x) \leq e^{-n\tilde{\lambda}(x)}$$

$$-\tilde{\lambda}(x) \leq \liminf \frac{1}{n}\log P(\overline{X})n \leq x).$$

Então:

$$\log P(\overline{X}_n \leq x) \leq -n\tilde{\lambda}(x) \ \ \therefore \ \ \frac{1}{n}\log P(\overline{X}_n \leq x) \leq -\tilde{\lambda}(x),$$

então,

$$\limsup \frac{1}{n}\log P(\overline{X}_n \leq x) \leq -\tilde{\lambda}(x),$$

e junto com o resultado do teorema de Cramèr-Chernoff para o lim inf:

$$\lim_{n\to\infty} \frac{1}{n} \log P(\overline{X}_n \leq x) = -\tilde{\lambda}(x), \;\; x \leq m.$$

Analogamente para $x \geq m$:

$$\lim_{n\to\infty} \frac{1}{n} \log P(\overline{X}_n \geq x) = -\tilde{\lambda}(x).$$

Assim, seja $x > \mathbb{E}X_1 = 0$ e $\varepsilon > 0$ tal que $x - \varepsilon \geq 0$:

$$\begin{aligned} l\big((x-\varepsilon, x+\varepsilon)\big) &= \lim \frac{1}{n} \log P(\overline{X}_n \in (x-\varepsilon, x+\varepsilon)) \leq \\ &\leq \lim \frac{1}{n} \log P(\overline{X}_n \in [x-\varepsilon, \infty)) = l\big([x-\varepsilon, \infty)\big) \leq \tilde{\lambda}(x-\varepsilon). \end{aligned}$$

Assim

$$-\lambda(x) = \lim_{\varepsilon\to 0} l\big(x-\varepsilon, x+\varepsilon)\big) \leq -\lim_{\varepsilon\to 0} \tilde{\lambda}(x-\varepsilon) = -\tilde{\lambda}(x^-)$$

onde $\tilde{\lambda}(x^-) = \lim_{y\to x^-} \tilde{\lambda}(y)$. Portanto:

$$\lambda(x) \geq \tilde{\lambda}(x^-), \;\; x > 0.$$

Agora, por outro lado, consideramos os seguintes resultados já conhecidos (a primeira e segunda parte da desigualdade abaixo são triviais):

$$\max\Big\{\underline{l}(A), \underline{l}(B)\Big\} \leq \underline{l}(A \cup B) \leq \overline{l}(A \cup B) \leq \max\Big\{\overline{l}(A), \overline{l}(B)\Big\}$$

$$-\tilde{\lambda}(x) \leq \liminf \frac{1}{n} \log P(\overline{X}_n \geq x), \; \forall x.$$

Então, para $x \geq 0$:

$$-\tilde{\lambda}(x) \leq \underline{l}\big([x,\infty]\big) \leq \overline{l}\big([x,\infty]\big) \leq \max\Big\{\overline{l}(\{x\}), \overline{l}\big((x,\infty)\big)\Big\}.$$

Pelo (1.1): o limite que de $\overline{l}$ existe: $\overline{l}((x,\infty)) = l((x,\infty))$. Pelo item (iv) do (1.2): $l((x,\infty)) = -\inf_{y>x} \lambda(y)$ e pelo item (ii) do (1.2): $\overline{l}(\{x\}) \leq -\inf_{y\in\{x\}} \lambda(y) = -\lambda(x)$.
Então:

$$\max\Big\{\overline{l}(\{x\}), \overline{l}\big((x,\infty)\big)\Big\} \leq -\min\Big\{\lambda(x), \inf_{y>x} \lambda(y)\Big\}$$

$$\Rightarrow \;\; -\tilde{\lambda}(x) \leq -\min\Big\{\lambda(x), \inf_{y>x} \lambda(y)\Big\}.$$

Como $x \geq 0$[5]

$$\lim_{y>x} \lambda(y) = \lim_{\varepsilon \to 0^+} \lambda(x+\varepsilon) = \lambda(x^+)$$

Portanto,

$$\min\left\{\lambda(x), \lambda(x^+)\right\} \leq \tilde{\lambda}(x).$$

Resumindo, temos:

$$\lambda(x) \geq \tilde{\lambda}(x^-), \;\; x > 0, \;\; \text{e} \;\; \min\left\{\lambda(x), \lambda(x^+)\right\} \leq \tilde{\lambda}(x), \;\; x \geq 0.$$

Consideramos a situação, então, na qual $\tilde{\lambda}$ é contínua em (r, p) e λ é contínua em $[s, q]$—situação descrita acima.
Com relação à p e q há três possibilidades: $p < q$, $p > q$ e $p = q$.
Se $p < q$ há, ainda três possibilidades:

(1) $0 \leq a < p < q$. Neste caso:

$$\tilde{\lambda}(a^-) = \tilde{\lambda}(a) \;\; \Rightarrow \;\; \lambda(a) \geq \tilde{\lambda}(a)$$

$$\lambda(a^+) = \lambda(a) \;\; \Rightarrow \;\; \lambda(a) \leq \tilde{\lambda}(a).$$

Ou seja, ocorre um absurdo.

(2) $0 < p < q < a$. Neste caso $\tilde{\lambda}(a) = \lambda(a) = \infty$.

(3) $0 < p < a < q$. Neste caso

$$\tilde{\lambda}(a^-) = \infty, \;\; \text{então} \;\; \lambda(a) \geq \tilde{\lambda}(a^-) = \infty \text{ não é satisfeita.}$$

Ou seja, outro absurdo.

Fazendo analises semelhantes para $p > q$ descobrimos que só nos resta $p = q$, e assim, $\lambda(x) = \tilde{\lambda}(x)$ para $x \geq 0$. Analogamente com relação à r e s concluímos que $r = s$ e $\lambda(x) = \tilde{\lambda}(x)$ para $x \leq 0$. $\square$

[5] λ é convexa e $\lambda(y) \geq \lambda(0) = 0$, $y > x$.

Referências

[1] S. Adams. *Large Deviations for Stochastic Processes*. 2012.

[2] P. Billingsley. *Ergodic Theory and Information*. Wiley series in probability and mathematical statistics. J. Wiley, 1965.

[3] M. Biskup. Reflection positivity and phase transitions in lattice spin models. *ArXiv Mathematical Physics e-prints*, Oct. 2006.

[4] R. Bissacot and R. Cioletti. *Introducao à Teoria das Medidas de Gibbs*. 2012.

[5] P. Bleher. Critical phenomena in the Dyson hierarchical model and renormalization group. *ArXiv e-prints*, Oct. 2010.

[6] D. Brydges and D. H. U. Marchetti. On the Virial Series for a Gas of Particles with Uniformly Repulsive Pairwise Interaction. *ArXiv e-prints*, Mar. 2014.

[7] D. C. Brydges and T. Kennedy. Mayer expansions and the hamilton-jacobi equation. *Journal of Statistical Physics*, 48(1):19–49, 1987.

[8] T. Carter. *An introduction to information theory and entropy*. 2014.

[9] A. Doering. The physical interpretation of daseinisation. *ArXiv e-prints*, Apr. 2010.

[10] I. Dolcetta, W. Fleming, and T. Zolezzi. *Recent Mathematical Methods in Dynamic Programming: Proceedings of the Conference held in Rome, Italy, March 26-28, 1984*. Lecture Notes in Mathematics. Springer Berlin Heidelberg, 2006.

[11] I. C. Dolcetta. *Representations of Solutions of Hamilton-Jacobi Equations*, pages 79–90. Birkhäuser Basel, Basel, 2003.

[12] A. Döring and C. Isham. "What is a Thing?": Topos Theory in the Foundations of Physics. In B. Coecke, editor, *Lecture Notes in Physics, Berlin Springer Verlag*, volume 813 of *Lecture Notes in Physics, Berlin Springer Verlag*, page 753, 2011.

[13] F. Dragoni. Limiting behavior of solutions of subelliptic heat equations. *Nonlinear Differential Equations and Applications NoDEA*, 14(3):429–441, 2007.

[14] R. Durrett. *Probability: Theory and Examples*. Cambridge Series in Statistical and Probabilistic Mathematics. Cambridge University Press, 2010.

[15] L. Evans. *Partial Differential Equations*. Graduate studies in mathematics. American Mathematical Society, 2010.

[16] A. Fathi. *The Weak KAM Theorem in Lagrangian Dynamics - 10th Preliminary Version*. 2008.

[17] J. Feng and T. Kurtz. *Large Deviations for Stochastic Processes:*. Mathematical Surveys and Monographs. American Mathematical Society, 2015.

[18] C. Flori. *A First Course in Topos Quantum Theory*. Lecture Notes in Physics. Springer Berlin Heidelberg, 2013.

[19] M. Freidlin, J. Szucs, and A. Wentzell. *Random Perturbations of Dynamical Systems*. Grundlehren der mathematischen Wissenschaften. Springer New York, 2012.

[20] H. Georgii. *Gibbs Measures and Phase Transitions*. De Gruyter studies in mathematics. De Gruyter, 2011.

[21] M. A. Giacomelli. *Grandes desvios no contexto de variáveis aleatórias independentes e identicamente distribuídas*. 1995.

[22] L. F. Guidi and D. H. U. Marchetti. Convergence of the Mayer Series via Cauchy Majorant Method with Application to the Yukawa Gas in the Region of Collapse. *ArXiv Mathematical Physics e-prints*, Oct. 2003.

[23] D. Ioffe. Stochastic geometry of classical and quantum ising models. *Lecture Notes in Mathematic*, 1970(6):87–126, 2009.

[24] D. Ioffe and A. Levit. Ground states for mean field models with a transverse component. *Journal of Statistical Physics*, 151(6):1140–1161, 2013.

[25] C. J. Isham. Topos Methods in the Foundations of Physics. *ArXiv e-prints*, Apr. 2010.

[26] M. Kac. On the partition function of a one-dimensional gas. *Physics of Fluids*, 2(1):8–12, 1959.

[27] M. Kac, G. E. Uhlenbeck, and P. C. Hemmer. On the van der waals theory of the vapor-liquid equilibrium. i. discussion of a one-dimensional model. *Journal of Mathematical Physics*, 4(2):216–228, 1963.

[28] R. Kraaij. Large deviations for finite state markov jump processes with mean-field interaction via the comparison principle for an associated hamilton–jacobi equation. *Journal of Statistical Physics*, 164(2):321–345, 2016.

[29] J. L. Lebowitz and O. Penrose. Rigorous treatment of the van der waals-maxwell theory of the liquid-vapor transition. *Journal of Mathematical Physics*, 7(1):98–113, 1966.

[30] M. Levi. *Classical Mechanics with Calculus of Variations and Optimal Control: An Intuitive Introduction*. Student Mathematical Library. American Mathematical Society, 2014.

[31] E. Lieb. Quantum-mechanical extension of the lebowitz-penrose theorem on the van der waals theory. *Journal of Mathematical Physics*, 7(6):1016–1024, 1966.

[32] D. H. U. Marchetti and J. Fernando Perez. The kosterlitz-thouless phase transition in two-dimensional hierarchical coulomb gases. *Journal of Statistical Physics*, 55(1):141–156, 1989.

[33] M. Mesterton-Gibbons. *A Primer on the Calculus of Variations and Optimal Control Theory*. Student mathematical library. American Mathematical Society, 2009.

[34] S. Molchanov and B. Vainberg. On the negative spectrum of the hierarchical Schrödinger operator. *ArXiv e-prints*, June 2012.

[35] C. M. Newman. Percolation theory: A selective survey of rigorous results. In G. Papanicolaou, editor, *Advances in Multiphase Flow and Related Problems*, pages 147–167. SIAM, 1986.

[36] E. Olivieri and M. Vares. *Large Deviations and Metastability*. Encyclopedia of Mathematics an. Cambridge University Press, 2005.

[37] A. Puhalskii. The method of stochastic exponentials for large deviations. *Stochastic Processes and their Applications*, 54(1):45 – 70, 1994.

[38] M. Reed and B. Simon. *I: Functional Analysis*. Methods of Modern Mathematical Physics. Elsevier Science, 1981.

[39] D. Ruelle. *Thermodynamic Formalism: The Mathematical Structure of Equilibrium Statistical Mechanics*. Cambridge Mathematical Library. Cambridge University Press, 2 edition, 2004.

[40] A. Shiryaev and R. Boas. *Probability*. Graduate Texts in Mathematics. Springer New York, 2013.

[41] E. Stein and R. Shakarchi. *Real Analysis: Measure Theory, Integration, and Hilbert Spaces*. Princeton University Press, 2009.

[42] G. E. Uhlenbeck and G. W. Ford. *Lectures in statistical mechanics*. Lectures in Applied Mathematics (Proceedings of the Summer Seminar, Boulder, Colorado, 1960), Vol. I, 1963.

[43] S. Varadhan. *Large Deviations and Applications*. CBMS-NSF Regional Conference Series in Applied Mathematics. Society for Industrial and Applied Mathematics, 1984.